



UNIVERSITÀ DEGLI STUDI DI PALERMO
DIPARTIMENTO DI INGEGNERIA

*LAUREA MAGISTRALE IN INGEGNERIA INFORMATICA -
INTELLIGENZA ARTIFICIALE*

**TECNICHE DI AML PER LA GENERAZIONE
DI ATTACCHI QUERY EFFICIENT**

Tesi di Laurea di
Giuseppe Ganci

Relatore:
Prof. Marco Morana

Controrelatore:
Prof. ?

Correlatore:
?

Indice

Introduzione	4
1 Stato dell'arte	5
1.1 I modelli Transformer	6
1.2 Vision Transformer	8
1.3 Tecniche di compressione dei modelli neurali	8
1.3.1 Quantizzazione	8
1.3.2 Knowledge Distillation	8
1.3.3 Pruning	8
1.3.4 Neural Architecture Search	8
2 Formulazione matematica del problema	9
2.1 Formulazione della ricerca	10
2.1.1 Branching	11
2.1.2 Bound	12
2.2 Formulazione delle Azioni di ricerca	13
2.3 Derivazione del criterio di importanza	19
2.4 Fisher Information Matrix ed Hessiano	21
3 Implementazione del Framework	24
3.1 Gestione e Divisione dei dati	24
3.2 Framework di Compressione Iterativo	25
3.3 Implementazione dell'algoritmo di ricerca	27
3.4 Implementazione delle azioni di Pruning	28

4	Esperimenti e risultati	30
4.1	Dataset utilizzati	30
4.1.1	CIFAR-100	30
4.2	Data Augmentation	31
4.3	Dettaglio implementativo	32
4.4	Metriche	33
4.5	Test sul dataset CIFAR-100	34
4.5.1	Test con ViT-Small	34
4.6	Analisi dell'algoritmo di ricerca	34
4.7	Ablazione	34
5	Caso di studio: deploy su mobile	37
	Conclusioni	38
	Ringraziamenti	39
	Elenco delle figure	40
	Bibliografia	41

Introduzione

Capitolo 1

Stato dell'arte

Gran parte dell'intelligenza artificiale moderna si fonda sull'utilizzo del **Deep Learning** [7], grazie alla sua capacità intrinseca di estrarre le *features* dai dati, superando i limiti del *Machine Learning* tradizionale. Ad oggi, il DL viene utilizzato in una grande varietà di domini, come l'elaborazione del linguaggio naturale, oppure la visione artificiale, o ancora la robotica. Tuttavia, le reti neurali *feed-forward* presentano una grave limitazione, ovvero l'assenza di uno stato interno, che non ne permette l'utilizzo con dati in sequenza, come i video, gli audio o il testo. Al fine di ovviare a questa mancanza, sono state introdotte le **Reti Neurali Ricorrenti**, specificatamente pensate per l'elaborazione di dati sequenziali di qualsiasi tipologia.




Figura 1.1: Rete Neurale Ricorrente e *unfolding*. Fonte: <https://commons.wikimedia.org/w/index.php?curid=60109157>

Nonostante la capacità teorica delle RNN di processare sequenze di lunghezza arbitraria, la loro applicazione pratica è limitata a causa di una serie di problematiche molto note. Come dimostrato matematicamente da Bengio et al. [2], l'addestramento di questi modelli è ostacolato dal

fenomeno della scomparsa o dell'esplosione del gradiente. Questa criticità rende estremamente difficile per il modello correlare informazioni distanti all'interno della sequenza temporale. Al fine di contrastare questi fenomeni nascono le reti **Long Short Term Memory** (LSTM) [5] e **Gated Recurrent Units** (GRU) [3], che introducono il concetto di *gating* per contrastare le problematiche legate al gradiente. Per anni questa tipologia di modelli ha costituito lo stato dell'arte per i dati sequenziali, nonostante delle limitazioni note, ad esempio la necessità di elaborare i dati in modo sequenziale (parola per parola nel caso di elaborazione del linguaggio naturale) rendendo impossibile la parallelizzazione del calcolo tramite hardware moderno (GPU), oppure la difficoltà con le dipendenze a lungo termine all'interno delle sequenze.

1.1 I modelli Transformer

I modelli *Transformer* trovano le loro origini nel meccanismo di **Attenzione**, nato anni prima nell'ambito dei modelli *encoder-decoder*, in particolare con le reti *seq2seq* [10], utilizzate nell'ambito della traduzione automatica. In questa tipologia di modelli il *decoder*, tipicamente costituito da una RNN, utilizza un unico vettore, lo stato finale dell'*encoder* (anche in questo caso si trattava solitamente di una RNN), che riassume la sequenza di input per poi generare l'output.




Figura 1.2: Inferenza con modelli *seq2seq*. Fonte: <https://github.com/d2l-ai/d2l-en>

La grande limitazione di questi modelli risiede proprio nell'utilizzo di un singolo vettore statico per la fase di decodifica, che non risulta sufficiente a riassumere adeguatamente la sequenza in input. Inoltre, se quest'ultima risulta particolarmente lunga, dato l'utilizzo di modelli RNN o LSTM, le informazioni legate ai primi dati in ingresso potevano essere perse a causa della grande distanza dallo stato finale. Allo scopo di superare i limiti del vettore di contesto

e migliorare quindi le prestazioni dei modelli *seq2seq* viene introdotto per la prima volta un meccanismo di attenzione da Bahdanau et al. [1].




Figura 1.3: Meccanismo di attenzione nei modelli *seq2seq*. Fonte: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

Questo meccanismo rende dinamico il vettore di contesto, che viene calcolato per ogni iterazione di decodifica pesando i contributi di tutti gli stati intermedi ottenuti dall'*encoder*. In questo modo è possibile fornire in input al modello *decoder* un vettore che riassume adeguatamente la sequenza in ingresso, dando maggiore importanza alle porzioni realmente rilevanti per l'output e migliorando nettamente le prestazioni dei modelli *seq2seq*.

Nonostante l'introduzione dell'attenzione abbia rappresentato una svolta nel superamento del limite costituito dal vettore di contesto statico, queste architetture rimanevano ancora profondamente legate alla natura sequenziale delle RNN o LSTM. In tale configurazione, l'attenzione agisce solo come un meccanismo ausiliario tra l'*encoder* e il *decoder*, e l'elaborazione dei dati avviene un passo alla volta, impedendo qualsiasi tipo di parallelizzazione dei calcoli. La vera rivoluzione si verifica con l'introduzione dell'architettura **Transformer** [12], che abbandona interamente l'approccio sequenziale delle reti ricorrenti per passare a quello delle reti *feed-forward*, utilizzando la **Multi-Head Self Attention**.

1.2 Vision Transformer

1.3 Tecniche di compressione dei modelli neurali

1.3.1 Quantizzazione

1.3.2 Knowledge Distillation

1.3.3 Pruning

1.3.4 Neural Architecture Search

Capitolo 2

Formulazione matematica del problema

Un problema di Neural Architecture Search (NAS) consiste in una ricerca in uno spazio degli stati, a partire da una architettura di partenza, detta **Supernet**, per identificare, tra tutte le possibili **Subnet**, quella che massimizza una determinata funzione obiettivo. In questo caso, al fine di ottenere una compressione di modelli *Transformer*, la ricerca si configura come un problema di **ottimizzazione multi-obiettivo**, tramite il quale vengono ottimizzate sia la performance del modello (attraverso l'accuratezza) sia la dimensione (attraverso il numero di parametri).

Uno dei problemi principali nell'ambito NAS è proprio la dimensione dello spazio degli stati, che risulta elevatissima, poiché il numero di possibili configurazioni cresce in maniera combinatoria rispetto al numero di componenti del modello. Nei Vision Transformer, ogni blocco Transformer presenta molteplici gradi di libertà: è possibile variare il numero di teste di attenzione nell'unità di *Multi-Head Attention* (MHSA), la dimensione dei vettori *Query-Key* e *Value*, ma anche la dimensione del livello nascosto nel modulo *Multi-Layer Perceptron* (MLP), ecc... Anche considerando un numero limitato di opzioni per ogni strato, il numero totale di subnet candidate diventa rapidamente intrattabile per una ricerca esaustiva.

Proprio per rendere trattabile l'esplorazione dello spazio degli stati è stata scelta una formulazione conveniente del problema, attraverso un algoritmo di ricerca *Branch and Bound* e l'utilizzo di azioni di *pruning* predefinite. Di seguito la formulazione matematica nel dettaglio.

2.1 Formulazione della ricerca

Dato un modello ViT M con parametri θ , definiamo un processo iterativo di pruning. Per ogni iterazione viene eseguita una ricerca di tipo *Depth First* a profondità limitata, ottimizzata tramite algoritmo *Branch and Bound*. Durante la ricerca verranno selezionate delle azioni da eseguire sul modello, e successivamente, attraverso un secondo problema combinatorio vengono selezionate le specifiche dimensioni da eliminare. L'obiettivo è massimizzare la seguente funzione rispetto alla maschera binaria m , ai parametri θ e al dataset di validazione D :

$$\max_m \text{Obj}(m, \theta, D) = \log_2(A(m, \theta, D)) - \lambda \cdot \log_2 \left(\frac{P(m, \theta)}{P_{tot}(\theta)} \right) \quad (2.1)$$

Dove:

- $m \in \{0, 1\}^N$ è la maschera di pruning globale, con N numero totale di parametri.
- La maschera è strutturata per blocchi: $m = \{m_{\text{emb}}, m^{(1)}, \dots, m^{(i)}, \dots, m^{(L)}\}$, con L numero di layer.
- Per ogni blocco i : $m^{(i)} = \{m_{\text{head}}, m_{\text{q_k}}, m_{\text{v_proj}}, m_{\text{mlp}}\}$.
- $A(m, \theta, D)$ indica l'accuratezza del modello mascherato sul dataset D .
- $P(m, \theta)$ rappresenta il numero di parametri attivi (non zero).
- $P_{tot}(\theta)$ rappresenta il numero totale di parametri del modello originale.

Notare che tramite questa formulazione è possibile ricondurre il problema in esame ad un **Problema di Programmazione Non Lineare Binario** (PNLPB). In questo contesto, le variabili decisionali sono rappresentate dai componenti della maschera $m \in \{0, 1\}^N$, mentre la non linearità è introdotta sia dalla natura della funzione di accuratezza A (legata ai pesi della rete neurale) sia dall'operatore logaritmico utilizzato nella funzione obiettivo. Nonostante esistano in letteratura delle tecniche di *Smoothing* delle variabili binarie per risolvere questo tipo di problemi combinatori, come quelle utilizzate da Murray et al. [9], i tempi di risoluzione, con un numero ridotto di variabili binarie rispetto al caso in esame, sono molto elevati. Proprio per tale motivo si è scelto di utilizzare un differente approccio algoritmico basato sul *Branch and Bound*.

2.1.1 Branching

L'esplorazione dello spazio di ricerca avviene tramite la costruzione di un apposito albero, seguendo un algoritmo di esplorazione *Depth First* a profondità limitata; di conseguenza, è possibile definire la strategia di esplorazione come **Depth Limited Depth First Branch and Bound** (DL-DFBnB).

La radice di questo albero è rappresentata dalla *Supernet*, ovvero il modello *Vision Transformer* di dimensione originale, specializzato su uno specifico dominio tramite *fine-tuning*. A partire dalla radice, viene eseguita la fase di **Branching** applicando le azioni di seguito elencate:

- **Pruning Multi-Layer Perceptron**
- **Pruning Query-Key**
- **Pruning Value-Projection**
- **Pruning Head**
- **Pruning Embedding**

Si noti che tutte le azioni, ad eccezione del *Pruning* dell'*Embedding*, sono locali a uno specifico blocco *Transformer*. La formalizzazione matematica delle singole azioni è rimandata alla sezione successiva.

Attraverso il *branching* viene costruito un **albero 5-ario** di ricerca, dove ogni nodo rappresenta una specifica *Subnet* ottenuta a partire dal nodo genitore. Ad ogni nodo viene associato un valore della funzione obiettivo, calcolato valutando l'accuratezza sul *Search Set* (utilizzando esclusivamente i parametri attivi) e il relativo numero di parametri residui. Questo valore verrà successivamente utilizzato per verificare i vincoli di *Bound* e, qualora risultasse più elevato del miglior valore individuato dalla ricerca, si aggiornerebbe quest'ultimo e si salverebbe la maschera di *Pruning* corrispondente.

Al fine di massimizzare l'efficacia della potatura, la strategia di esplorazione *Depth First* è stata scelta per favorire il raggiungimento dei nodi foglia dell'albero di ricerca. Questo permette all'algoritmo di individuare rapidamente configurazioni caratterizzate da un elevato numero di azioni di *pruning* e, di conseguenza, da una significativa riduzione dei parametri.

L'introduzione di un limite di profondità nell'albero di ricerca permette di mitigare l'impatto cumulativo del *pruning* sulle prestazioni del modello. Un'esplorazione eccessivamente profonda,

infatti, comporterebbe una rimozione massiva di parametri, rischiando di degradare l'accuratezza in modo irreversibile. In tali scenari, il danno strutturale all'architettura potrebbe risultare troppo elevato, rendendo difficoltoso il recupero delle performance originali anche attraverso l'impiego di tecniche avanzate come la *Knowledge Distillation*.

2.1.2 Bound

La dimensione dell'albero di ricerca risulta significativa; in particolare, detta D la massima profondità dell'albero, e considerato che si tratta di un albero 5-ario, il numero totale di nodi è pari a:

$$N = \sum_{i=0}^D 5^i \quad (2.2)$$

Ad esempio, se $D = 6$, il numero totale di nodi è pari a 19.531. Considerando che per ogni nodo è necessario calcolare i gradienti per tutti i parametri attivi del modello al fine di stimare l'importanza, il tempo necessario per una ricerca esaustiva risulterebbe proibitivo. Tale criticità viene risolta attraverso la fase di **Bound**, che permette di effettuare un *pruning on-the-fly* sull'albero di ricerca, escludendo interi rami computazionalmente onerosi ma poco promettenti dal punto di vista della funzione obiettivo.

In particolare, per ogni nodo n esplorato, viene verificato il seguente vincolo di ammissibilità:

$$\text{Obj}(n) > \text{Obj}_{best} - \varepsilon \quad (2.3)$$

Qualora il vincolo venisse violato, il nodo non verrebbe sottoposto a *Branching*, troncando di fatto l'esplorazione di quel ramo. È importante sottolineare la presenza del **fattore di tolleranza** ε : esso consente alla ricerca di non arrestarsi prematuramente, permettendo l'esplorazione di subnet che, pur essendo leggermente inferiori al miglior valore individuato (Obj_{best}), si trovano in regioni dello spazio degli stati potenzialmente ottimali. Questo approccio garantisce una ricerca più robusta e completa, anche se maggiormente onerosa in termini computazionali.

2.2 Formulazione delle Azioni di ricerca

Per ogni nodo dell'albero di ricerca, l'applicazione delle azioni di *pruning* genera i cinque nodi figli corrispondenti. Ciascuna azione identifica un gruppo specifico di parametri W_g all'interno dell'architettura che può essere rimosso minimizzando il degrado delle prestazioni del modello.

Al fine di individuare le componenti meno rilevanti per le capacità predittive del modello, viene adottata una metrica di importanza basata sulla sensibilità della funzione di perdita rispetto ai parametri. Per un singolo parametro w , l'importanza è definita come:

$$I(w) = w^2 \cdot \mathbb{E}_{x \sim D} \left[\left(\frac{\partial L(x; \theta^*)}{\partial w} \right)^2 \right] \quad (2.4)$$


Dove $L(x; \theta^*)$ è proprio la funzione di perdita, calcolata a partire dai parametri attivi θ^* , sul *Search Set* (x). Operando un *pruning strutturato*, l'importanza di un intero gruppo di parametri W_g (come un intero neurone) viene calcolata come la somma dei contributi individuali:

$$I(W_g) = \sum_{w \in W_g} I(w) \quad (2.5)$$

Le specifiche azioni di *pruning* possono essere definite come un problema di minimizzazione locale volto a identificare il gruppo di dimensioni (formate da più parametri) g la cui rimozione minimizza l'impatto sulla funzione di perdita L . Le azioni agiscono sui singoli blocchi, al fine di mantenere i requisiti di dimensionalità degli acceleratori hardware. Per garantire la compatibilità tra il modello compresso e l'hardware pensato per l'accelerazione di questi modelli (es. Tensor Core), imponiamo un vincolo di cardinalità $|g| = K$ (con K multiplo di 8). Di seguito la formulazione matematica dettagliata per ogni singola azione:

- **Pruning MLP:** Sia B l'insieme dei blocchi *Transformer* e $MLP_{b_i} = \{g \subset W_{MLP, b_i} : |g| = K\}$ l'insieme dei possibili raggruppamenti di cardinalità K di dimensioni del modulo MLP nel blocco i -esimo. L'azione identifica il gruppo g_{MLP}^* che minimizza:

$$g_{MLP}^* = \arg \min_{\substack{b_i \in B \\ g_K \in MLP_{b_i}}} \sum_{W_g \in g_K} I(W_g) \quad (2.6)$$



MLP Pruning

Figura 2.1: Visualizzazione delle matrici dei pesi mascherate dall'azione di *MLP Pruning*.

- **Pruning QK (Query-Key):** Sia B l'insieme dei blocchi *Transformer* e $QK_{b_i} = \{g \subset W_{QK, b_i} : |g| = K\}$ l'insieme dei raggruppamenti di K dimensioni condivise tra i moduli Query e Key di tutte le teste di attenzione del blocco i -esimo. L'azione identifica il gruppo g_{QK}^* che minimizza:

$$g_{\text{QK}}^* = \arg \min_{\substack{b_i \in B \\ g_K \in QK_{b_i}}} \sum_{W_g \in g_K} I(W_g) \quad (2.7)$$




Figura 2.2: Visualizzazione delle matrici dei pesi mascherate dall'azione di *QK Pruning*, nella *MHSA*.

- **Pruning VPROJ (Value-Projection):** Sia B l'insieme dei blocchi *Transformer* e $VP_{b_i} = \{g \subset W_{VP, b_i} : |g| = K\}$ l'insieme dei raggruppamenti di cardinalità K di dimensioni dei moduli *Value* e *Output Projection* di tutte le teste di attenzione nel blocco i -esimo. L'azione identifica il gruppo g_{VP}^* che minimizza:

$$g_{VP}^* = \arg \min_{\substack{b_i \in B \\ g_K \in VP_{b_i}}} \sum_{W_g \in g_K} I(W_g) \quad (2.8)$$




Figura 2.3: Visualizzazione delle matrici dei pesi mascherate dall'azione di *VProj Pruning*, nella *MHSA*.

- **Pruning HEAD:** Sia B l'insieme dei blocchi *Transformer* e $H_{b_i} = \{h \in \text{HEADS}_{b_i}\}$ l'insieme di tutte le teste di attenzione nel blocco i -esimo. L'azione identifica la head h^* che minimizza:

$$h^* = \arg \min_{\substack{b_i \in B \\ h \in H_{b_i}}} \sum_{W_g \in h} I(W_g) \quad (2.9)$$




Figura 2.4: Visualizzazione delle matrici dei pesi mascherate dall'azione di *Head Pruning*, nella *MHSA*.

- **Pruning EMB (Embedding):** Sia $EMB = \{g \subset W_{EMB} : |g| = K\}$ l'insieme di tutti i raggruppamenti di cardinalità K di dimensioni dell'*Embedding* nell'intero modello *Transformer*. L'azione identifica il gruppo g_{EMB}^* che minimizza:

$$g_{EMB}^* = \arg \min_{g_K \in EMB} \sum_{W_g \in g_K} I(W_g) \quad (2.10)$$

Si noti che, a differenza delle azioni precedenti, il *Pruning* dell'*Embedding* opera sulla dimensione globale del modello. La rimozione di un raggruppamento g_K in questa fase comporta una potatura della rappresentazione vettoriale che si propaga attraverso l'intera architettura, influenzando la dimensione di tutti i blocchi *Transformer*.




Figura 2.5: Visualizzazione delle matrici dei pesi mascherate dall'azione di *Emb Pruning*, nella *MHSA*.




Figura 2.6: Visualizzazione delle matrici dei pesi mascherate dall'azione di *Emb Pruning*, nella *FFN*.

2.3 Derivazione del criterio di importanza

La metrica di importanza utilizzata combina le informazioni sulla magnitudo dei pesi e dei gradienti, al fine di misurare la sensibilità di uno specifico parametro, a partire dai dati in input al modello. I parametri meno sensibili vengono interpretati come di scarso contributo all'output del modello, e di conseguenza vengono potati. La derivazione della metrica di importanza considera un singolo parametro w e il suo effetto sulla funzione di perdita L . In particolare si analizza la variazione di L al variare di w :

$$\Delta L = L(w + \delta w) - L(w) \quad (2.11)$$

$$L(w + \delta w) = L(w) + \Delta L \quad (2.12)$$

Per approssimare il valore della *loss function* con il nuovo valore del parametro $L(w + \delta w)$ si utilizza l'espansione di Taylor al primo ordine:

$$L(w + \delta w) \approx L(w) + \frac{\partial L}{\partial w} \cdot \delta w + O(w) \quad (2.13)$$

Dato che l'operazione effettuata è la potatura, il valore del parametro perturbato è zero (in quanto viene tagliato) e di conseguenza $\delta w = -w$, da cui possiamo ottenere il valore approssimato della variazione di L :

$$L(w + \delta w) - L(w) \approx (-w) \cdot \frac{\partial L}{\partial w} \quad (2.14)$$

Applicato ad un gruppo di parametri W_g (ad esempio un intero neurone):

$$\Delta L(W_g) = \sum_{w \in W_g} \Delta L(w) = \sum_{w \in W_g} -w \cdot \frac{\partial L}{\partial w} = - \sum_{w \in W_g} w \cdot \frac{\partial L}{\partial w} \quad (2.15)$$

Nonostante l'approssimazione al primo ordine sia ampiamente sfruttata in letteratura per la sua semplicità computazionale, essa introduce un rischio sistematico nel caso del pruning strutturato. Si consideri un gruppo di parametri W_g contenente due parametri w_1 e w_2 . Nell'eventualità in cui le variazioni individuali della perdita siano opposte, ovvero $\Delta L(w_1) \approx -\Delta L(w_2)$, la loro

somma algebrica risulterebbe prossima allo zero:

$$\Delta L(W_g) = \sum_{w \in W_g} \Delta L(w) \approx 0 \quad (2.16)$$

Tale risultato porterebbe l'algoritmo a classificare erroneamente il gruppo W_g come irrilevante, quando in realtà è possibile che i singoli parametri possiedano un'elevata sensibilità. Poiché ΔL è una stima lineare e locale della reale superficie della funzione di perdita, fare affidamento sulla somma dei contributi segnati espone a decisioni di potatura errate, dove componenti critiche vengono rimosse a causa di una reciproca compensazione dei gradienti.

La soluzione a questo problema può essere individuata in un approccio più conservativo, utilizzando i quadrati per permettere la somma dei contributi individuali (che saranno così sempre positivi):

$$I(W_g) = \sum_{w \in W_g} \Delta L(w)^2 = \sum_{w \in W_g} \left(w \cdot \frac{\partial L}{\partial w} \right)^2 \quad (2.17)$$

Notare che il calcolo del gradiente $\frac{\partial L}{\partial w}$ non è banale, infatti accumulando semplicemente i gradienti, si rischia di incorrere in un fenomeno di cancellazione, ad esempio detti b_1 e b_2 i due (unici) *batch* di dati in input, potrebbe accadere che:

$$\frac{\partial L}{\partial w}(b_1) \approx -\frac{\partial L}{\partial w}(b_2) \quad (2.18)$$

Che in fase di accumulo, porterebbe ad un gradiente complessivo circa nullo, azzerando erroneamente l'importanza del parametro.

La soluzione a questo problema può essere facilmente individuata nell'utilizzo del valore atteso di $g^2 = \left(\frac{\partial L}{\partial w} \right)^2$, da cui:

$$I(w) = w^2 \cdot \mathbb{E}_{x \sim D}[g^2] = w^2 \cdot \frac{1}{N} \sum_{i=1}^N g_i^2 \quad (\text{medie sui batch}) \quad (2.19)$$

con N numero di *batch* in input e g_i il gradiente della funzione di perdita, calcolato sul *batch* i -esimo.

Date queste premesse, è possibile definire la seguente metrica di importanza per un gruppo di

parametri W_g :

$$I(W_g) = \sum_{w \in W_g} w^2 \cdot \mathbb{E}_{x \sim D} \left[\left(\frac{\partial L(x)}{\partial w} \right)^2 \right] \quad (2.20)$$

2.4 Fisher Information Matrix ed Hessiano

La metrica di importanza derivata nella sezione precedente combina l'informazione fornita dalla magnitudo dei parametri con l'approssimazione diagonale della **Matrice di Informazione di Fisher**, estremamente utilizzata per determinare l'importanza dei parametri nelle reti neurali (ad es. [8] [11]), così definita:

$$F(w) = \mathbb{E}_{x,y} [\nabla L(y, f(x, w)) \cdot \nabla L(y, f(x, w))^T] \in \mathbb{R}^{|w| \times |w|} \quad (2.21)$$

Nel quale i singoli elementi rappresentano la correlazione tra i gradienti dei singoli parametri:

$$F(w_i, w_j) = \mathbb{E}_{x,y} \left[\frac{\partial L}{\partial w_i} \cdot \frac{\partial L}{\partial w_j} \right] \quad (2.22)$$

Data la cardinalità dei parametri nei modelli *Transformer*, il calcolo e la memorizzazione della matrice completa risultano computazionalmente proibitivi. Si assume pertanto l'indipendenza tra i parametri, operazione che equivale a considerare esclusivamente la diagonale della matrice:

$$F(w_i, w_j) = 0 \quad \text{ed} \quad F(w_i, w_i) = \mathbb{E}_{x,y} \left[\left(\frac{\partial L}{\partial w_i} \right)^2 \right]$$

Empiricamente, tale valore, detto **Informazione di Fisher**, viene stimato tramite una semplice media su un numero N di *batch* (x_k) in input:

$$F(w) = \frac{1}{N} \sum_{k=1}^N \left(\frac{\partial L(x_k)}{\partial w} \right)^2 \quad (2.23)$$

Notare che esiste un profondo legame tra l'*Informazione di Fisher* e l'*Hessiano* della funzione di perdita. Ad una simile conclusione sono giunti anche Theis et. al [11]. Di seguito la dimostrazione formale di questo legame, assumendo che la funzione di perdita sia la *Negative*

Log-Likelihood.

Consideriamo un problema di classificazione in cui il modello definisce una distribuzione di probabilità $p(y|x, w)$. Per la proprietà di normalizzazione, la somma delle probabilità su tutte le classi $y \in Y$ è unitaria:

$$\sum_{y \in Y} p(y|x, w) = 1 \quad (2.24)$$

Derivando rispetto ai parametri w :

$$\nabla_w \sum_y p(y|x, w) = 0 \implies \sum_y \nabla_w p(y|x, w) = 0 \quad (2.25)$$

Utilizzando una semplice proprietà delle derivate, per cui $\nabla p = p \frac{\nabla p}{p} = p \nabla \log(p)$, possiamo riscrivere l'espressione come:

$$\sum_y p(y|x, w) \cdot \nabla_w \log p(y|x, w) = 0 \quad (2.26)$$

Per brevità di notazione, assumiamo $p(y|x, w) = p(y)$ e deriviamo una seconda volta rispetto a w :

$$\nabla_w \sum_y p(y) \cdot \nabla_w \log p(y) = 0 \quad (2.27)$$

Applicando la regola del prodotto:

$$\sum_y [\nabla_w p(y) \cdot \nabla_w \log p(y)^T + p(y) \cdot \nabla_w^2 \log p(y)] = 0 \quad (2.28)$$

Sostituendo nuovamente $\nabla_w p(y) = p(y) \nabla_w \log p(y)$, otteniamo:

$$\sum_y [p(y) \nabla_w \log p(y) \cdot \nabla_w \log p(y)^T + p(y) \cdot \nabla_w^2 \log p(y)] = 0 \quad (2.29)$$

Raccogliendo $p(y)$, che rappresenta la distribuzione di probabilità della variabile aleatoria y nel valore atteso $\mathbb{E}_y$, arriviamo alla relazione fondamentale:

$$\sum_y p(y) [\nabla_w \log p(y) \nabla_w \log p(y)^T + \nabla_w^2 \log p(y)] = 0 \quad (2.30)$$

Da questa relazione, si può notare come $\nabla_w \log p(y) \nabla_w \log p(y)^T$ sia proprio il termine legato alla Matrice di Fisher, mentre $\nabla_w^2 \log p(y)$ è il termine legato all'Hessiano. In particolare, si evince che il valore atteso della Fisher Information e dell'Hessiano sono legati dalla relazione:

$$\mathbb{E}_{x,y}[\text{Fisher}] + \mathbb{E}_{x,y}[\text{Hessiano}] = 0 \implies \mathbb{E}_{x,y} [\nabla \log p \nabla \log p^T] = -\mathbb{E}_{x,y} [\nabla^2 \log p] \quad (2.31)$$

Considerato che è assunto l'utilizzo della funzione di perdita Cross-Entropy, che corrisponde alla Negative Log-Likelihood (NLL) nel caso della classificazione:

$$L = -\log p(y_{true}|x, w) \quad (2.32)$$

Le derivate prima e seconda rispetto ai parametri sono dunque:

$$\nabla L = -\nabla \log p, \quad \nabla^2 L = -\nabla^2 \log p \quad (2.33)$$

Sostituendo queste identità nella relazione precedente, otteniamo l'equivalenza finale:

$$\mathbb{E}_{x,y} [\nabla L \cdot \nabla L^T] = \mathbb{E}_{x,y} [\nabla^2 L] \quad (2.34)$$

Il che implica, per le singole componenti diagonali:

$$\mathbb{E}_{x,y} \left[\left(\frac{\partial L}{\partial w_i} \right)^2 \right] = \mathbb{E}_{x,y} \left[\frac{\partial^2 L}{\partial w_i^2} \right] \quad (2.35)$$

Considerazioni teoriche

Sebbene la teoria garantisca che la matrice di Fisher approssimi l'Hessiano, è importante sottolineare che tale equivalenza è strettamente valida solo quando il modello rappresenta correttamente la distribuzione dei dati reali, ovvero in condizioni di convergenza, come descritto approfonditamente da Kunstner et al. [6]. Nel metodo proposto, questa assunzione è considerata verificata poiché l'estrazione della metrica di importanza avviene su modelli che sono stati sottoposti ad una fase di fine-tuning. In tale stato di stabilità e convergenza, la *Fisher Information* fornisce una stima affidabile della curvatura della funzione di perdita, permettendo di identificare con precisione i parametri la cui rimozione minimizza l'impatto sulle prestazioni del Transformer.

Capitolo 3

Implementazione del Framework

In questo capitolo viene esposto l'intero framework di compressione proposto, costruito sulle fondamenta teoriche esposte nel Capitolo 2.

3.1 Gestione e Divisione dei dati

Nella fase iniziale il framework di compressione prevede di istanziare il dataset. In particolare, inizialmente viene eseguita la suddivisione in *Dati di Train* e *Dati di Test*, successivamente i primi vengono ulteriormente divisi in *Training Set* e *Validation Set*. Il secondo di questi verrà utilizzato esclusivamente per monitorare l'accuratezza del modello durante le iterazioni di compressione. Per quanto concerne il *Training Set*, questo viene utilizzato alla fine di ogni iterazione per eseguire una serie di epoche di *Fine Tuning*, al fine di permettere un riadattamento dei parametri del modello, ma anche come sorgente da cui estrarre il *Search Set*.

Quest'ultimo è formato da un numero ben preciso di campioni per classe N , che costituisce un iper-parametro del processo di compressione, in questo modo la sua dimensione corrisponde ad $N \times |Classes|$. Dagli esperimenti effettuati emerge un valore ottimale di N di 25 campioni per classe, poiché permette una buona approssimazione dei gradienti, ma allo stesso tempo consente di mantenere contenuto il tempo necessario alla fase di ricerca NAS. Infatti, il *Search Set* viene utilizzato su ogni nodo dell'albero di ricerca (ovvero su ogni *Subnet*) sia per il calcolo della metrica di importanza per ogni parametro (che prevede quindi un passo di *backpropagation*, dal grande costo computazionale), sia per la valutazione dell'accuratezza.

Per evitare che la fase di ricerca, utilizzando un unico *Search Set* per tutte le iterazioni, provochi un ***Overfitting Architettuale***, con conseguenti difficoltà di generalizzazione del modello compresso, il *Search Set* viene **campionato ad ogni iterazione** a partire dal *Training Set*, fornendo campioni differenti all'algoritmo NAS, di iterazione in iterazione. Questo permette di ottenere un modello risultante che è in grado di generalizzare al meglio sul problema di classificazione, proprio perché l'architettura finale, è il risultato ottenuto con una maggiore quantità e varietà di dati.

Un altro contributo fondamentale al mantenimento della capacità di generalizzazione del modello, è dato dalla **Data Augmentation**, che viene sempre applicata al *Search Set*, ed è la stessa che viene applicata ai dati del *Training Set*. Si potrebbe pensare che questo introduca rumore nei gradienti, e quindi influenzi la precisione e l'affidabilità della metrica di importanza. Nella pratica però il problema del rumore è fortemente limitato dall'utilizzo della media dei gradienti sui batch, per il calcolo della metrica di importanza, com'è possibile osservare nella Formula (2.4). La *Data Augmentation* applicata al *Search Set* è risultata molto efficace, nei test effettuati, per impedire che venissero sacrificate delle dimensioni del modello essenziali per mantenere la sua capacità di generalizzazione, traducendosi in questo modo in valori di accuratezza sul *Test Set* e sul *Validation Set* più elevati durante tutta l'esecuzione del framework.

Notare che è possibile interpretare il framework di compressione come un **ottimizzazione a due livelli** del modello. In particolare il livello superiore è occupato dal processo di ricerca NAS, che esegue un vero e proprio **training architettuale**, mentre il livello inferiore è quello del *Fine Tuning*, che invece si occupa di **ottimizzare i parametri**, date le modifiche architetture operate dal livello superiore. Questa visione del metodo permette di comprendere al meglio le motivazioni dietro la specifica gestione dei dati, ed in particolare del *Search Set*. Infatti, l'applicazione di tecniche di *data augmentation* a quest'ultimo implica una dinamicità che contribuisce a scongiurare il fenomeno dell'*overfitting architettuale*, analogamente a come tecniche quali l'*early stopping* o i *Learning Rate Scheduler* vengono impiegate per prevenire l'*overfitting* dei parametri del modello.

3.2 Framework di Compressione Iterativo

Una volta definita la strategia di gestione dei dati, è necessario definire la struttura del framework di compressione iterativo, in particolare cosa avviene ad ogni iterazione.

Inizialmente viene campionato il *Search Set*, in modo tale da poterlo utilizzare in fase di ricerca NAS. Successivamente inizia la prima fase dell'iterazione: il **Pruning**. La prima operazione che viene eseguita è l'algoritmo di ricerca *BnB*, che verrà analizzato nella sezione ??, il quale restituisce lo stato migliore individuato, ovvero una maschera di *pruning* per l'intero modello.

A questo punto la maschera viene applicata al modello, e questo viene successivamente ricostruito istanziando tutti i tensori dei parametri ed effettuando una copia solo di quelli non tagliati in fase di ricerca. Viene quindi creato un nuovo modello *ViT*, del quale sono state effettivamente ridotte le dimensioni e questo risulta fondamentale perché implica che il framework proposto non si limita ad applicare delle maschere di *pruning*, che non avrebbero alcun impatto sulle prestazioni effettive del modello sull'hardware, bensì produce dei nuovi modelli di dimensioni realmente minori, con prestazioni realmente superiori. In particolare viene ridotta la latenza in fase di inferenza ma anche la memoria necessaria (VRAM) per utilizzare il modello.

Una volta ricostruito il modello, dato che la fase di *Pruning*, avrà introdotto un danno alle performance del modello, è necessario passare alla successiva fase di **Recovery Fine Tuning**. Si tratta di una serie di epoche di addestramento, volte a consentire ai parametri rimasti del modello di riadattarsi, per poter recuperare l'accuratezza perduta. Risulta fondamentale in questa fase la possibilità di introdurre la *Knowledge Distillation* tramite il modello originale non compresso, che permette tipicamente un recupero più efficace della performance del modello.

Algorithm 1 Framework di Compressione Iterativo

```

1: Input: Pre-trained model  $M_0$ , Dataset  $\mathcal{D}$ , Iterations  $N$ , Fine Tuning epochs  $K$ 
2: Output: Compressed and optimized model  $M$ 
3:  $M_{teacher} \leftarrow M_0$  ▷ Original model used for distillation
4:  $M \leftarrow M_0$ 
5: for  $n \leftarrow 1$  to  $N$  do
6:    $\mathcal{D}_{search} \leftarrow \text{sample\_search\_set}(\mathcal{D}_{train})$  ▷ Dynamic sampling of the search set
7:    $m_{pruning} \leftarrow \text{pruning\_NAS}(M, \mathcal{D}_{search})$  ▷ NAS to obtain pruning mask
8:    $M_{pruned} \leftarrow \text{compress\_ViT}(M, m_{pruning})$  ▷ Rebuilding ViT
9:    $M \leftarrow M_{pruned}$ 
10:   $M \leftarrow \text{FineTuning}(M, M_{teacher}, \mathcal{D}_{train}, \mathcal{D}_{val}, K)$ 
11: end for
12: return  $M$ 

```

3.3 Implementazione dell'algoritmo di ricerca

In questa sezione viene dettagliata l'implementazione della fase di ricerca con algoritmo *Branch and Bound*, che viene eseguito all'inizio di ogni iterazione di compressione.

Algorithm 2 Ricerca NAS via Depth-First Branch and Bound a profondità limitata

```

1: Input: Base Model  $M$ , Depth Limit  $D_{max}$ 
2: Output: Optimal State  $s_{best}$ , Optimal State value  $v_{best}$ 
3:  $s_{init} \leftarrow \text{build\_initial\_state}()$ 
4:  $stack \leftarrow [s_{init}]$  ▷ Stack setup
5:  $M_{work} \leftarrow \text{copy}(M)$ 
6:  $s_{best} \leftarrow s_{init}$ 
7:  $v_{best} \leftarrow -\infty$ 
8: while  $stack$  is not empty do
9:    $s_{curr} \leftarrow stack.pop()$ 
10:   $\text{reset\_masks}(M_{work})$ 
11:   $\text{apply\_masks}(M_{work}, s_{curr})$ 
12:   $\text{accuracy}, \text{active\_params} \leftarrow \text{evaluate}(M_{work})$  ▷ Subnet evaluation
13:   $v_{curr} \leftarrow \text{compute\_obj}(\text{acc}, \text{active\_params})$ 
14:  if  $v_{curr} > v_{best}$  then
15:     $v_{best}, s_{best} \leftarrow v_{curr}, s_{curr}$ 
16:  end if
17:  if  $D_{max}$  reached OR  $\text{Bound}(v_{curr}, v_{best})$  then ▷ Bound or depth limit reached
18:    continue
19:  end if
20:  // Branching
21:   $\text{next\_states} \leftarrow \text{Branch}(s_{curr}, M_{work})$ 
22:  for  $s$  in  $\text{next\_states}$  do
23:     $stack.push(s)$ 
24:  end for
25: end while
26: return  $s_{best}, v_{best}$ 

```

Al fine di evitare una eccessiva occupazione di memoria, il processo di ricerca fa utilizzo di stati costituiti come strutture dati a dizionario, invece che vere e proprie copie del modello originale. All'interno di ogni stato è presente una struttura che, per ogni blocco *Transformer* contiene tutte le dimensioni rimosse per ogni tipologia di struttura (MLP, QK, ecc...), oltre ad una informazione generale su quali dimensioni di *Embedding* sono state tagliate globalmente.

A partire da questa struttura dati è possibile agire su una serie di maschere di *pruning* che vengono applicate al modello, permettendo così di ottenere la vera e propria *subnet*. Per garantire la massima efficienza queste maschere vengono applicate ad un'unica copia del modello iniziale, che, alla fine di ogni esplorazione dello stato vede le proprie maschere reimpostate, per poter applicare i tagli previsti dal successivo stato della ricerca.

3.4 Implementazione delle azioni di Pruning

Data la formulazione matematica delle azioni di ricerca, presentata nella sezione 2.2, in fase di implementazione, considerato l'elevatissimo numero di dimensioni nel modello, viene adottato un approccio più efficiente. In particolare, non vengono considerate realmente tutte le possibili combinazioni di dimensioni a K a K di un componente del modello, poiché, dato che è di interesse la somma delle importanze delle singole dimensioni, è sufficiente considerare le K dimensioni le cui importanze sono minime. In particolare, per tutte quelle azioni che agiscono all'interno di un singolo blocco (ovvero tutte tranne il *Pruning* della dimensione di *Embedding*), vengono identificate, per ogni blocco *Transformer* le K dimensioni con il minor valore di importanza. Successivamente, viene selezionato il blocco, il cui gruppo di dimensioni ottimali, hanno una importanza complessiva minore. Questo tipo di approccio semplifica e rende la risoluzione del problema più efficiente.

Per quanto riguarda il *Pruning* della dimensione di *Embedding*, l'approccio adottato è il medesimo, con la differenza che, essendo questa una dimensione globale, non vengono considerati singolarmente i blocchi ma complessivamente, riducendo l'algoritmo all'individuazione dei K minimi valori di importanza sull'intero modello.

Algorithm 3 Selezione del gruppo di dimensioni ottimale per il taglio

```
1: Input: Model  $M$ , Chunk size  $K$ , Target component  $T$ 
2: Output: (block, [dimension indices]) Target dimension group
3:  $v_{best\_imp} \leftarrow \infty$ 
4:  $target \leftarrow \text{null}$ 
5: for every block  $b$  in  $M.blocks$  do
6:   if number of dimensions in  $T(b) < K$  then
7:     continue
8:   end if
9:    $candidates \leftarrow \emptyset$ 
10:  for every dimension  $d$  in  $T(b)$  do
11:    if  $d$  is already pruned then
12:      continue
13:    end if
14:     $imp_d \leftarrow \text{importance\_score}(d)$ 
15:     $candidates.append((d, imp_d))$ 
16:  end for
17:   $candidates \leftarrow \text{sort}(candidates, \text{ascending} = \text{True})$ 
18:   $chunk \leftarrow candidates[0 : K]$ 
19:   $v_{block\_imp} \leftarrow \sum_{(d,i) \in chunk} i$ 
20:  if  $v_{block\_imp} < v_{best\_imp}$  then
21:     $v_{best\_imp} \leftarrow v_{block\_imp}$ 
22:     $target \leftarrow (b, chunk.indices)$ 
23:  end if
24: end for
25: return  $target$ 
```

Capitolo 4

Esperimenti e risultati

In questo capitolo vengono presentati i risultati ottenuti dal framework realizzato, tramite una serie di esperimenti che coinvolgono modelli e dataset differenti.

Tutti gli esperimenti vengono svolti con modelli **ViT**, preaddestrati sul dataset **ImageNet**, che lavorano con *patch* di dimensione **16×16** e immagini in *input* di tipo **RGB** con risoluzione **224×224**.

4.1 Dataset utilizzati

Di seguito vengono presentati i dataset utilizzati nei test effettuati sul framework.

4.1.1 CIFAR-100

Il primo dataset utilizzato per testare il framework è stato il **CIFAR100**, che è stato selezionato poiché molto diffuso in letteratura, in cui è utilizzato come **benchmark standard** per compiti di classificazione. Risulta più complesso rispetto al *CIFAR10*, ma mantiene dimensioni ridotte e quindi permette una ottima rapidità di *training*. In particolare *CIFAR100* contiene **60.000 immagini** totali, suddivise in **50.000** immagini di addestramento e **10.000** di validazione, tutte della risoluzione di **32×32** e di tipo **RGB**.

Per i test sul dataset *CIFAR100* è stata effettuata una ulteriore suddivisione del *set* di addestramento con rapporto **90/10**, in modo tale da ottenere un **Train Set** finale di **45.000** immagini e un **Held-Out Set** di **5.000** immagini, quest'ultimo utilizzato per il monitoraggio del processo di

compressione.




Figura 4.1: Esempio di immagini dal dataset CIFAR100.

4.2 Data Augmentation

Data la la grande capacità dei modelli *Vision Transformer*, per scongiurare il rischio di *overfitting*, sono state adottate delle tecniche di **Data Augmentation**, in particolare:

- **Random Resized Crop:** Questa tecnica estrae una porzione casuale dell'immagine originale con un'area compresa tra l'**80%** e il **100%** della dimensione iniziale. Successivamente, il ritaglio viene ridimensionato alla risoluzione *target* di 224×224 pixel.
- **Random Horizontal Flip:** Consiste nel riflettere l'immagine orizzontalmente con una probabilità del **50%**.
- **Color Jitter:** Questa trasformazione applica variazioni casuali alla luminosità, al contrasto e alla saturazione dell'immagine, con un fattore di distorsione impostato a **0.3** per ciascun parametro.

Queste sono state utilizzate per il dataset CIFAR100.

4.3 Dettaglio implementativo

Di seguito i dettagli implementativi delle fasi di *Fine Tuning* dei modelli, durante la compressione. Per il primo *Fine Tuning*:

- **Ottimizzatore AdamW** con un fattore di **decadimento dei pesi** pari a **0.05** e con **learning rate discriminativi**: 0.5×10^{-5} per il *backbone* del *Transformer* e 0.5×10^{-4} per la testa di classificazione.
- **Scheduler** dei *learning rate* di tipo **Cosine Annealing**.
- Dimensione dei **batch** di *training* pari a **128** campioni.
- **30 epoche** di addestramento con **early stopping**.

Per quanto riguarda invece la fase di **Recovery Fine-Tuning**, volta a ripristinare le prestazioni dopo il taglio dei parametri, adotta la medesima configurazione di ottimizzazione del *Fine-Tuning* iniziale, con due variazioni: l'impiego di un **learning rate unico** pari a 0.5×10^{-5} per l'intera rete e un limite massimo di **20 epoche** di addestramento, sufficienti per stabilizzare i pesi della *subnet* individuata.

Infine, per quanto concerne i test con la **Knowledge Distillation (KD)**, è stata implementata una versione *logit-based* seguendo l'approccio proposto da *Hinton et al.* [4]. Il modello **teacher**, in tutti i test, consiste nel modello *ViT* che fa da *Baseline*, ovvero quello integro, non sottoposto ad

alcuna compressione. La funzione di **loss composita** utilizzata durante il *Recovery Fine-Tuning* integra un termine di distillazione con temperatura $\tau = 4.0$. A tale componente è stato assegnato un **peso relativo pari a 0.9**, privilegiando così il trasferimento della conoscenza dal modello *teacher* alla *subnet* compressa. Questa configurazione ha permesso di ammorbidire le distribuzioni di probabilità dei *logits*, consentendo al modello *student* di apprendere non solo le etichette corrette, ma anche le relazioni strutturali tra le classi catturate dal modello completo. Di seguito i risultati dei test.

4.4 Metriche

Per valutare le prestazioni dei modelli nei test effettuati, e di conseguenza per valutare l'efficacia del framework di compressione, sono state utilizzate le seguenti metriche:

- **Numero di Parametri:** consiste nella quantità di parametri rimasti al modello, dopo l'esecuzione del processo di compressione.
- **Accuracy:** al fine di valutare le prestazioni del modello sul task di riferimento, viene utilizzata la *Top-1 Accuracy*, valutata sui dati di test del dataset utilizzato.
- **GFLOPs:** si tratta del numero di *Floating Point Operations* (operazioni in virgola mobile) che sono necessarie per eseguire un singolo passaggio di inferenza (*forward pass*) sul modello. In particolare 1 GFLOP corrisponde ad 1×10^9 operazioni in virgola mobile. A differenza della latenza, che risulta legata all'hardware utilizzato, i GFLOPs forniscono una misura deterministica della complessità computazionale del modello.
- **Throughput:** consiste nel numero di immagini al secondo che vengono processate dal modello, e viene calcolato costruendo un batch di immagini "fittizie", ovvero ottenute tramite la generazione di un tensore randomico, e successivamente misurando il tempo necessario al modello per eseguire l'inferenza su tale tensore.
- **Latency:** viene calcolata insieme alla precedente, e misura (in ms) il tempo necessario per l'inferenza di un singolo batch di immagini.

4.5 Test sul dataset CIFAR-100

4.5.1 Test con ViT-Small

In questi test è stato utilizzato un modello **ViT-Small** da **21.7 Mln** di parametri, a cui è stata aggiunta una testa di classificazione da **100 unità**, e successivamente sottoposto a *Fine Tuning* iniziale sul dataset in oggetto. Per quanto riguarda il framework, tutti i test sono stati effettuati con **15 iterazioni** di compressione. In ogni iterazione, la **profondità** dell'albero di ricerca è stata limitata a **6**, questo implica che, per ogni iterazione, al modello possono essere applicate massimo **6 azioni consecutive** di *pruning*. Viene inoltre utilizzata una **soglia di tolleranza** della fase di *Bound* pari a **0.005**, in modo tale da permettere una ricerca più approfondita dello spazio di ricerca, al costo di un numero lievemente maggiore di nodi esplorati. Infine, la **funzione obiettivo** utilizza un valore di λ pari a **1.0**, attribuito al contributo dei parametri.

Modello	Parametri (M)	Top-1 Acc. (%)	GFLOPs	Throughput	Latency
Baseline	21.67	90.42%	4.60	1137.5	112.5
Pruned	15.93 (-26.6%)	89.59% (-0.83%)	3.42 (-25.51%)	1405.5 (+23.56%)	91.1 (-19.02%)
Pruned+KD	15.78 (-27.3%)	89.86% (-0.56%)	3.39 (-26.19%)	1406.0 (+23.60%)	91.0 (-19.11%)

Tabella 4.1: Nella tabella sono presentati i risultati comparativi utilizzando il *ViT-Small* e il dataset *CIFAR100*, in particolare vengono evidenziati i valori delle metriche e le variazioni rispetto al modello *Baseline*.

4.6 Analisi dell'algoritmo di ricerca

Fare test con la loss nella funzione obbiettivo, poi un altro senza la soglia nel bound e con vari valori.

4.7 Ablazione

Al fine di verificare la bontà del metodo sono stati effettuati dei test per isolare il contributo delle due principali componenti del *framework*, l'algoritmo di ricerca e la metrica di importanza.

I seguenti risultati sono stati ottenuti sul dataset CIFAR100, utilizzando la stessa configurazione riportata nella sezione 4.5 e nella sezione 4.3. I test sono stati eseguiti senza l'utilizzo della *Knowledge Distillation* per isolare al meglio l'effetto delle singole componenti del framework. Di seguito i risultati:

Modello	Parametri (M)	Top-1 Acc. (%)	GFLOPs	Throughput	Latency
Baseline	21.67	90.42%	4.60	1137.5	112.5
ViT-S Pruned (No KD)	15.93 (-26.6%)	89.59% (-0.83%)	3.43 (-25.51%)	1405.5 (+23.56%)	91.1 (-19.02%)
Ricerca Disattivata	12.28 (-43.4%)	81.17% (-9.25%)	2.64 (-42.66%)	1679.9 (+47.68%)	76.2 (-32.27%)
Metrica Disattivata	19.38 (-10.7%)	89.07% (-1.35%)	4.09 (-11.09%)	1147.9 (+00.09%)	111.5 (-00.09%)

Tabella 4.2: Nella tabella sono presentati i risultati dell'applicazione del *framework* di compressione nella sua interezza e con le componenti disattivate, sul dataset *CIFAR100* e sul modello *ViT-Small*.

Come è possibile notare, entrambi i test di ablazione hanno dato risultati peggiori rispetto a quanto ottenuto con il *framework* di compressione nella sua interezza. In particolare nel test con la **ricerca disattivata**, per ogni iterazione, considerando d la massima profondità della ricerca, vengono eseguite casualmente d azioni sul modello. In questo caso il *framework* si è trovato costretto ad eseguire dei tagli su dimensioni importanti, e quindi poco conservativi dal punto di vista delle performance. La metrica di importanza, mantenuta attiva nel test, non è riuscita a limitare i danni portati dai tagli molto aggressivi e indiscriminati, portando così ad una grande diminuzione di accuratezza. Questo primo test ha dimostrato che l'algoritmo di ricerca *BnB* ha un grande contributo nel selezionare accuratamente le azioni, da un lato limitando il livello di compressione a parità di iterazioni di *pruning*, dall'altro consentendo di mantenere dei livelli di prestazioni molto vicini al modello originale.

Nel secondo test invece, la **metrica di importanza** è stata disattivata, di conseguenza per ogni azione selezionata dall'algoritmo di ricerca, viene prima selezionato casualmente il blocco *Encoder* su cui agire, e successivamente vengono campionate casualmente le dimensioni da tagliare delle specifiche componenti (QK, MLP, ...) di quel blocco (tranne per la dimensione di *Embedding*, per il quale non è necessario selezionare prima il blocco su cui agire). I risultati indicano chiaramente una difficoltà dell'algoritmo di ricerca nell'esplorare lo spazio degli stati, causata proprio dalla mancanza dell'azione della metrica di importanza. Selezionando in maniera casua-

le le dimensioni da tagliare, la maggioranza degli stati (*subnet*) che vengono esplorati risultano poco promettenti e peggiorano il valore della funzione obbiettivo, con un conseguente aumento del numero di nodi esplorati, ed una grande fatica a comprimere il modello. Durante i test che fanno uso della metrica di importanza, si assiste invece ad una progressione stabile e rapida del valore della funzione obbiettivo, che si dimostra quindi molto efficace nel guidare le azioni di *pruning* e la ricerca.

In questo secondo test è importante notare come le prestazioni del modello si sono mantenute elevate, a conferma del grande lavoro di filtraggio eseguito dal processo di ricerca, che evita di selezionare quegli stati, la cui selezione casuale dei tagli, ha danneggiato gravemente il modello.

Capitolo 5

Caso di studio: deploy su mobile

Conclusioni

Ringraziamenti

Elenco delle figure

1.1	Rete Neurale Ricorrente e <i>unfolding</i> . Fonte: https://commons.wikimedia.org/w/index.php?curid=60109157	5
1.2	Inferenza con modelli <i>seq2seq</i> . Fonte: https://github.com/d2l-ai/d2l-en	6
1.3	Meccanismo di attenzione nei modelli <i>seq2seq</i> . Fonte: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html	7
2.1	Visualizzazione delle matrici dei pesi mascherate dall'azione di <i>MLP Pruning</i> . .	14
2.2	Visualizzazione delle matrici dei pesi mascherate dall'azione di <i>QK Pruning</i> , nella <i>MHSA</i>	15
2.3	Visualizzazione delle matrici dei pesi mascherate dall'azione di <i>VProj Pruning</i> , nella <i>MHSA</i>	16
2.4	Visualizzazione delle matrici dei pesi mascherate dall'azione di <i>Head Pruning</i> , nella <i>MHSA</i>	17
2.5	Visualizzazione delle matrici dei pesi mascherate dall'azione di <i>Emb Pruning</i> , nella <i>MHSA</i>	18
2.6	Visualizzazione delle matrici dei pesi mascherate dall'azione di <i>Emb Pruning</i> , nella <i>FFN</i>	18
4.1	Esempio di immagini dal dataset CIFAR100.	31

Bibliografia

- [1] D. Bahdanau, K. Cho e Y. Bengio. *Neural Machine Translation by Jointly Learning to Align and Translate*. 2016. arXiv: [1409.0473 \[cs.CL\]](https://arxiv.org/abs/1409.0473). URL: <https://arxiv.org/abs/1409.0473>.
- [2] Y. Bengio, P. Simard e P. Frasconi. «Learning long-term dependencies with gradient descent is difficult». In: *IEEE Transactions on Neural Networks* 5.2 (1994), pp. 157–166.
- [3] K. Cho, B. van Merriënboer, Ç. Gülçehre, F. Bougares, H. Schwenk e Y. Bengio. «Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation». In: *CoRR* abs/1406.1078 (2014). arXiv: [1406.1078](https://arxiv.org/abs/1406.1078). URL: <http://arxiv.org/abs/1406.1078>.
- [4] G. Hinton, O. Vinyals e J. Dean. *Distilling the Knowledge in a Neural Network*. 2015. arXiv: [1503.02531 \[stat.ML\]](https://arxiv.org/abs/1503.02531). URL: <https://arxiv.org/abs/1503.02531>.
- [5] S. Hochreiter e J. Schmidhuber. «Long Short-Term Memory». In: *Neural Computation* 9.8 (1997), pp. 1735–1780.
- [6] F. Kunstner, L. Balles e P. Hennig. *Limitations of the Empirical Fisher Approximation for Natural Gradient Descent*. 2020. arXiv: [1905.12558 \[cs.LG\]](https://arxiv.org/abs/1905.12558). URL: <https://arxiv.org/abs/1905.12558>.
- [7] e. G. H. LeCun Y. Bengio. *Deep Learning*. 2015. URL: <https://doi.org/10.1038/nature14539>.
- [8] P. Molchanov, A. Mallya, S. Tyree, I. Frosio e J. Kautz. *Importance Estimation for Neural Network Pruning*. 2019. arXiv: [1906.10771 \[cs.LG\]](https://arxiv.org/abs/1906.10771). URL: <https://arxiv.org/abs/1906.10771>.

- [9] W. Murray e K.-M. Ng. *An algorithm for nonlinear optimization problems with binary variables*. 2010. URL: <https://link.springer.com/article/10.1007/s10589-008-9218-1>.
- [10] I. Sutskever, O. Vinyals e Q. V. Le. «Sequence to Sequence Learning with Neural Networks». In: *CoRR* abs/1409.3215 (2014). arXiv: [1409.3215](https://arxiv.org/abs/1409.3215). URL: <http://arxiv.org/abs/1409.3215>.
- [11] L. Theis, I. Korshunova, A. Tejani e F. Huszár. *Faster gaze prediction with dense networks and Fisher pruning*. 2018. arXiv: [1801.05787](https://arxiv.org/abs/1801.05787) [cs.CV]. URL: <https://arxiv.org/abs/1801.05787>.
- [12] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser e I. Polosukhin. «Attention Is All You Need». In: *CoRR* abs/1706.03762 (2017). arXiv: [1706.03762](https://arxiv.org/abs/1706.03762). URL: <http://arxiv.org/abs/1706.03762>.